rbiezt9l7

January 9, 2025

1 LIBRAIRIES, CLASS & FUNCTIONS

[1]:
```
# Librairies
import yfinance as yf

import pandas as pd
import numpy as np
import warnings

%matplotlib inline
import matplotlib.pyplot as plt
from matplotlib.pylab import rcParams

from datetime import datetime

from arch import arch_model

from statsmodels.tsa.seasonal import seasonal_decompose
from statsmodels.tsa.stattools import adfuller
from statsmodels.tsa.arima.model import ARIMA
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.stats.diagnostic import acorr_ljungbox
import statsmodels.api as sm

import scipy.stats as stats

import torch
import torch.nn as nn
from torch.utils.data import DataLoader, Dataset

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import LSTM, Dense

from sklearn.preprocessing import MinMaxScaler
from sklearn.metrics import mean_squared_error, mean_absolute_error

from tqdm import tqdm
```

```python
rcParams['figure.figsize'] = 15, 6

# Ignorer les avertissements
warnings.filterwarnings("ignore")
```

[2]:
```python
# Fonctions
## Function to calculate technical indicators
def calculate_indicators(data):
    """
    Calculates technical indicators for the given data.

    Parameters:
        data (pd.DataFrame): A DataFrame containing at least a 'Close' column␣
 ↪representing closing prices.

    Returns:
        pd.DataFrame: The original DataFrame with two additional columns:
            - 'MA10Day': 10-day moving average of the closing prices.
            - 'MA30Day': 30-day moving average of the closing prices.
    """
    data['MA10Day'] = data['Close'].rolling(window=10).mean()
    data['MA30Day'] = data['Close'].rolling(window=30).mean()
    return data

## RSI Calculation
def calculate_rsi(series, period):
    """
    Calculates the Relative Strength Index (RSI) for a given time series.

    Parameters:
        series (pd.Series): A series of prices for which RSI is to be␣
 ↪calculated.
        period (int): The lookback period for calculating RSI.

    Returns:
        pd.Series: A series containing the RSI values.
    """
    delta = series.diff()
    gain = (delta.where(delta > 0, 0)).rolling(window=period).mean()
    loss = (-delta.where(delta < 0, 0)).rolling(window=period).mean()
    rs = gain / loss
    rsi = 100 - (100 / (1 + rs))
    return rsi

## Fonction to calculate mse, rmse and mae
def calculate_metrics(y_true, y_pred):
```

```
    """
    Calculates common regression metrics: Mean Squared Error (MSE), Root Mean␣
↪Squared Error (RMSE),
    and Mean Absolute Error (MAE).

    Parameters:
        y_true (array-like): Ground truth (true values).
        y_pred (array-like): Predicted values.

    Returns:
        tuple: A tuple containing the following metrics:
            - mse (float): Mean Squared Error.
            - rmse (float): Root Mean Squared Error.
            - mae (float): Mean Absolute Error.
    """
    mse = mean_squared_error(y_true, y_pred)
    rmse = np.sqrt(mse)
    mae = mean_absolute_error(y_true, y_pred)
    return mse, rmse, mae
```

[3]:
```
# Classe du modèle
class BiLSTMModel(nn.Module):
    """
    Modèle BiLSTM pour la prédiction de séries temporelles ou de séquences,␣
↪basé sur une architecture
    de réseaux de neurones récurrents bidirectionnels (BiLSTM).

    Arguments :
    - input_size (int) : Nombre de caractéristiques d'entrée à chaque pas de␣
↪temps.
    - hidden_size (int) : Nombre de neurones dans la couche cachée.
    - num_layers (int) : Nombre de couches LSTM empilées.
    - output_size (int) : Taille de la sortie du modèle, c'est-à-dire le nombre␣
↪de prédictions.
    """

    def __init__(self, input_size, hidden_size, num_layers, output_size):
        """
        Initialisation du modèle BiLSTM avec les paramètres spécifiés.

        Arguments :
        - input_size (int) : Nombre de caractéristiques d'entrée à chaque pas␣
↪de temps.
        - hidden_size (int) : Nombre de neurones dans la couche cachée.
        - num_layers (int) : Nombre de couches LSTM empilées.
        - output_size (int) : Taille de la sortie du modèle.
        """
```

```
        super(BiLSTMModel, self).__init__()
        self.lstm = nn.LSTM(input_size, hidden_size, num_layers,␣
↪batch_first=True, bidirectional=True)
        self.fc = nn.Linear(hidden_size * 2, output_size)

    def forward(self, x):
        """
        Passe avant du modèle. Effectue la propagation avant à travers la␣
↪couche LSTM et la couche linéaire.

        Arguments :
        - x (tensor) : Tenseur d'entrée de forme (batch_size, seq_length,␣
↪input_size).

        Retour :
        - out (tensor) : Tenseur de sortie de forme (batch_size, output_size).
        """
        _, (h_n, _) = self.lstm(x)
        h_n = torch.cat((h_n[-2], h_n[-1]), dim=1)  # Concatenate both␣
↪directions
        out = self.fc(h_n)

        return out
```

2 DATA PREPROCESSING

2.1 Import dataset

[ ]:
```
# Data downloading
ticker = "NVDA"
start_date = "2010-01-01"
end_date = "2024-12-31"

data = yf.download(ticker, start=start_date, end=end_date)
```

[ ]:
```
# Création de la colonne Date
nvidia_df = data.reset_index()
nvidia_df.Date = pd.to_datetime(nvidia_df.Date)

# Affichage des données
nvidia_df.head()
```

[ ]:

Price	Date	Close	High	Low	Open	Volume
Ticker		NVDA	NVDA	NVDA	NVDA	NVDA
0	2010-01-04	0.423923	0.426903	0.415210	0.424381	800204000
1	2010-01-05	0.430113	0.434698	0.422318	0.422318	728648000

```
2      2010-01-06  0.432864  0.433781  0.425757  0.429884  649168000
3      2010-01-07  0.424381  0.432406  0.421171  0.430572  547792000
4      2010-01-08  0.425298  0.428279  0.418420  0.420942  478168000
```

[51]:
```python
nvidia_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3773 entries, 0 to 3772
Data columns (total 6 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   (Date, )         3773 non-null   datetime64[ns]
 1   (Close, NVDA)    3773 non-null   float64
 2   (High, NVDA)     3773 non-null   float64
 3   (Low, NVDA)      3773 non-null   float64
 4   (Open, NVDA)     3773 non-null   float64
 5   (Volume, NVDA)  3773 non-null   int64
dtypes: datetime64[ns](1), float64(4), int64(1)
memory usage: 177.0 KB
```

Chaque ligne représente les données boursières quotidiennes de l'action NVIDIA (NVDA) et les colonnes contiennent des indicateurs financiers :

Close : Prix de clôture (valeur à la fin de la journée).

High : Prix le plus élevé atteint dans la journée.

Low : Prix le plus bas atteint dans la journée.

Open : Prix à l'ouverture de la journée.

Volume : Volume des transactions effectuées (en nombre d'actions échangées).

2.2 Exploratory Data Analysis (EDA):

Faisons une analyse simple de nos données pour avoir un aperçu des données traitées

[52]:
```python
# Statistiques descriptives
nvidia_df.drop(columns=[('Date',)]).describe().round(2)
```

[52]:

Price	Close	High	Low	Open	Volume
Ticker	NVDA	NVDA	NVDA	NVDA	NVDA
count	3773.00	3773.00	3773.00	3773.00	3.773000e+03
mean	13.95	14.20	13.67	13.95	4.970860e+08
std	28.03	28.55	27.47	28.05	3.064658e+08
min	0.20	0.21	0.20	0.20	4.564400e+07
25%	0.41	0.42	0.40	0.41	3.034880e+08
50%	3.54	3.59	3.45	3.52	4.283480e+08
75%	13.56	13.82	13.33	13.59	6.025800e+08
max	148.87	152.88	146.25	149.34	3.692928e+09

- Les données montrent une forte croissance du prix de l'action NVIDIA au fil des années, avec une variabilité significative.
- Le volume de transactions est également élevé, indiquant que l'action est très liquide et fréquemment échangée.
- Les statistiques descriptives révèlent des tendances intéressantes à explorer plus en détail, comme la relation entre le volume et les variations de prix.

[53]:
```python
# Tracer toutes les colonnes par rapport à la date
nvidia_df.plot(x='Date', subplots=True, figsize=(16, 8), title='NVIDIA Stock␣
↪Data')
plt.show()
```

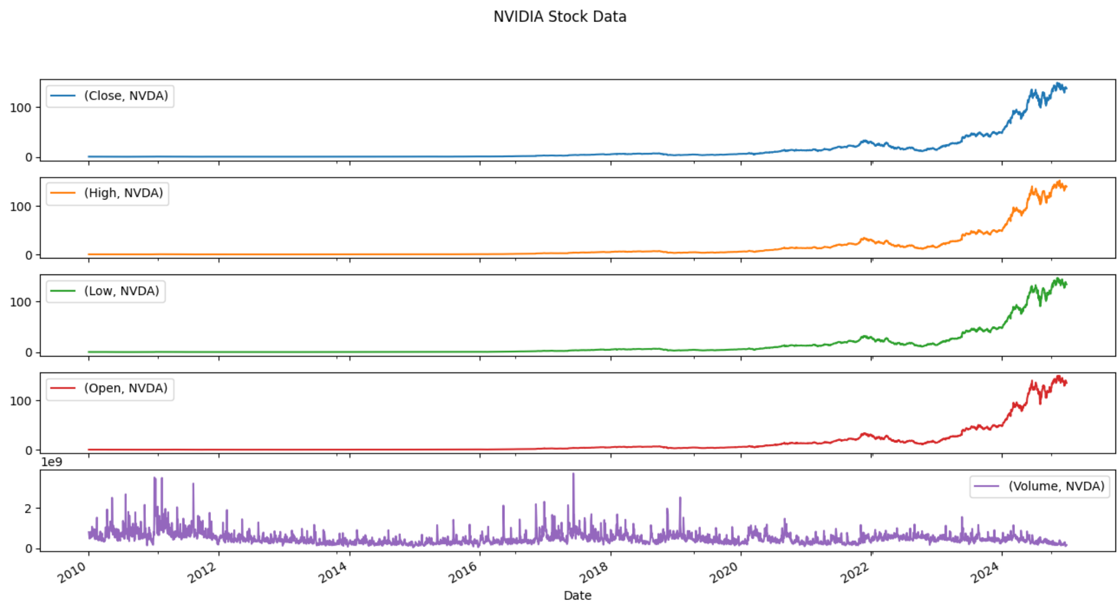

- **Prices**
  - Le graphique montre clairement l'évolution des **prix de l'action** au fil du temps. On observe une **croissance exponentielle** des prix à partir de certaines périodes, surtout après 2020. Ces variations sont probablement liées à des événements marquants, comme des annonces importantes ou des résultats financiers qui ont eu un fort impact.
  - On remarque aussi des **périodes de forte volatilité**, où le prix fluctue de manière significative. Ces fluctuations peuvent être le résultat d'événements externes ou de changements dans les conditions du marché, affectant directement l'action de NVIDIA.
- **Volume**
  - Le graphique du **volume de transactions** nous montre l'intensité des échanges d'actions. On peut facilement repérer des **pics de volume**, qui sont souvent associés à des événements majeurs pour la société, tels que des lancements de produits, des résultats financiers ou même des événements de marché comme des crises économiques ou des événements politiques.
  - En dehors de ces pics, on observe des périodes où le volume reste relativement **stable**, ce

qui peut indiquer que le marché est dans une phase plus calme, sans grands changements ou nouvelles importantes.

- **Croissance**
  - On voit bien que les prix ont montré une croissance substantielle, particulièrement après 2020. Cela reflète sûrement l'impact de la **révolution technologique** et la demande croissante pour les produits NVIDIA, notamment dans des secteurs clés comme l'**intelligence artificielle** et les **jeux vidéo**, qui ont alimenté cette forte progression.

2.3 Séparation des données en train et test

Pour notre étude, nous tâcherons de prédire le prix de cloture.

Et on chosit arbitrairement de travailler avec les données des 6 derniers mois comme données test pour nos modèles à venir.

[54]:
```
# Filtrer les données pour l'ensemble train et test
nvidia_df_train = nvidia_df[(nvidia_df['Date'] >= '2020-01-01') &␣
 ↪(nvidia_df['Date'] <= '2024-05-31')]
nvidia_df_test = nvidia_df[(nvidia_df['Date'] >= '2024-06-01') &␣
 ↪(nvidia_df['Date'] <= '2024-12-31')]

# Afficher quelques lignes des deux DataFrames
print(nvidia_df_train.tail())
print('-'*30)
print(nvidia_df_test.head())

# Diviser les données en X et y
X, y = nvidia_df.drop(columns=['Date']), nvidia_df['Close']
X_train, y_train = nvidia_df_train.drop(columns=['Date']),␣
 ↪nvidia_df_train['Close']
X_test, y_test = nvidia_df_test.drop(columns=['Date']), nvidia_df_test['Close']
```

```
Price         Date       Close        High         Low        Open     Volume
Ticker                    NVDA        NVDA        NVDA        NVDA       NVDA
3622    2024-05-24  106.443810  106.449805  102.975629  104.424283  429494000
3623    2024-05-28  113.874054  114.911810  109.857007  110.217921  652728000
3624    2024-05-29  114.797836  115.464678  110.874769  113.023262  557442000
3625    2024-05-30  110.473862  115.791604  109.637062  114.622882  487350000
3626    2024-05-31  109.607071  112.690341  106.914707  112.493381  613263000
------------------------------
Price         Date       Close        High         Low        Open     Volume
Ticker                    NVDA        NVDA        NVDA        NVDA       NVDA
3627    2024-06-03  114.972794  114.972794  111.976501  113.594122  438392000
3628    2024-06-04  116.409454  116.572418  114.018022  115.688632  403324000
3629    2024-06-05  122.411034  122.420027  117.440210  118.342996  528402000
3630    2024-06-06  120.969383  125.557295  118.292015  124.018657  664696000
3631    2024-06-07  120.859406  121.663216  117.994086  119.741666  412386000
```

3 MODELS SELECTION

3.1 ARIMA MODEL

Le modèle **ARIMA (AutoRegressive Integrated Moving Average)** est couramment utilisé pour prédire les séries temporelles, en particulier lorsqu'il existe des tendances ou des cycles dans les données. Dans notre approche, nous avons utilisé ARIMA pour modéliser l'évolution des **prix de l'action** de NVIDIA à partir de sa série temporelle. Avant d'appliquer ce modèle, nous avons d'abord observé les **prix** (ou rendements) de l'action pour détecter d'éventuelles tendances ou variations cycliques dans le temps.

- 1. **Observation des prix :** Avant d'appliquer le modèle ARIMA, nous avons analysé les **prix historiques** de l'action NVIDIA. Ces prix sont influencés par des facteurs externes tels que les nouvelles économiques, les performances financières de l'entreprise, et les événements mondiaux. Nous avons identifié des tendances et des patterns dans les données, ce qui nous a permis de déterminer que l'utilisation d'un modèle ARIMA pourrait être appropriée pour la prédiction des prix futurs.
- 2. **Analyse de la tendance et de la stationnarité :** Avant d'appliquer ARIMA, une étape cruciale est de vérifier la **stationnarité** de la série temporelle. Une série est dite stationnaire si ses propriétés statistiques, telles que la moyenne et la variance, sont constantes dans le temps. Les séries temporelles de prix, comme celles des actions, ont souvent des **tendances** qui les rendent non stationnaires, et il est donc nécessaire de les rendre stationnaires avant de les utiliser dans le modèle. Pour ce faire, nous avons appliqué une **differencing** (ou différenciation) qui permet d'éliminer les tendances et de rendre la série stationnaire.
- 3. **Modèle ARIMA :** Le modèle **ARIMA** repose sur trois principaux composants :
  - **AR (AutoRegressive)** : Ce terme prend en compte les rendements passés pour prédire les valeurs futures de la série temporelle. Autrement dit, la valeur future dépend des observations passées de manière linéaire.
  - **I (Integrated)** : Ce terme permet de rendre la série stationnaire en calculant les différences successives. Il est essentiel pour transformer des séries non stationnaires en séries stationnaires.
  - **MA (Moving Average)** : Ce terme prend en compte les erreurs passées de la série temporelle pour prédire les valeurs futures, ce qui permet d'atténuer l'impact des bruits aléatoires.

Ainsi, le modèle ARIMA est utilisé pour capturer **les dépendances temporelles** dans les prix des actions de NVIDIA. En ajustant les paramètres du modèle ARIMA (p, d, q), nous cherchons à trouver la combinaison optimale qui permet de mieux prévoir les valeurs futures.

- 4. **Démarche de prédiction avec ARIMA :** Dans notre cas, après avoir observé les tendances dans les prix de l'action, nous appliquons le modèle ARIMA pour prédire les **valeurs futures** des prix. Le modèle prend en compte les **valeurs passées** et les **erreurs passées** pour effectuer ces prévisions. Il est particulièrement utile dans les séries temporelles présentant des tendances ou des cycles. L'objectif est de prévoir l'évolution future des prix de l'action NVIDIA, ce qui est crucial pour la prise de décision en investissement.

L'objectif de ce processus est d'obtenir une **prévision robuste** des prix futurs, en tenant compte des données passées, ce qui nous permet de mieux évaluer les perspectives d'évolution des prix de l'action de NVIDIA. Nous allons maintenant passer à la présentation du code qui suit cette approche théorique.

3.1.1 Preprocessing

On choisit de travaille sur les mensualités. En sachant qu'en finnace, 1 mois est considéré par 20 jours ouvrés

[ ]:
```
# Décomposition de la série temporelle
decomposition = seasonal_decompose(y_train, model='additive', period=20)
decomposition.plot()
plt.show()
```

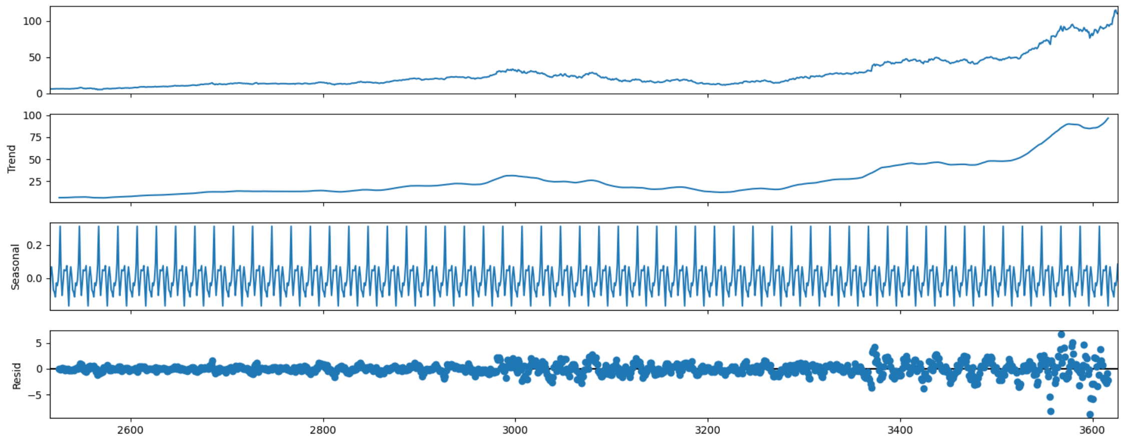

[ ]:
```
# Tendance
tendance = decomposition.trend

plt.figure(figsize=(14, 4))
tendance.plot()
plt.suptitle('Tendance')
plt.show()
```

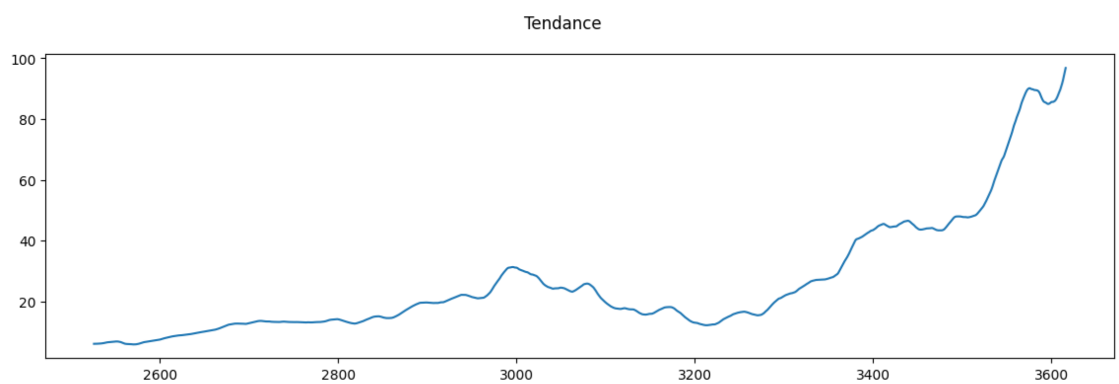

La **décomposition de la série temporelle** révèle plusieurs aspects importants de l'évolution des prix de l'action de NVIDIA.

- **Tendance (Trend) :**
  - On peut clairement observer une **tendance haussière fluctuante** au fil du temps, indiquant une **croissance** des prix, surtout dans les dernières années.
- **Saisonnière (Seasonal) :**
  - Le graphique montre également des **variations saisonnières** dans les prix, ce qui suggère que les prix de l'action suivent un certain **cycle répétitif**, peut-être en lien avec des événements réguliers dans le secteur technologique, comme les annonces de nouveaux produits ou les résultats financiers trimestriels.
  - On remarque des **périodes de fluctuation récurrente**, peut-être en relation avec des tendances spécifiques à certains mois ou trimestres de l'année.
- **Résidu (Residual) :**
  - Les **résidus** montrent les variations qui ne peuvent être expliquées par la tendance ou la saisonnalité. On observe des **fluctuations aléatoires**, ce qui peut être attribué à des événements extérieurs imprévus, comme des crises économiques ou des annonces non planifiées qui affectent le marché de manière ponctuelle.

En somme, la décomposition met en évidence une croissance stable à long terme des prix de l'action, avec des cycles saisonniers et des événements imprévus qui influencent les prix de manière plus volatile.

[ ]:
```python
# on teste la stationnarité de la série
print('Série Close NVDA')
print('-'*30)
# Effectuer le test de Dickey-Fuller augmenté
result = adfuller(y_train)

# Extraire les résultats
adf_statistic = result[0]
p_value = result[1]
critical_values = result[4]

# Afficher les résultats
print('ADF Statistic:', adf_statistic)
print('p-value:', p_value)
print('Critical Values:')
for key, value in critical_values.items():
    print(f'   {key}: {value}')

# Déterminer si la série est stationnaire
if adf_statistic < critical_values['5%']:
    print('-'*30)
    print("La série est stationnaire.")
else:
```

```
    print('-'*30)
    print("La série n'est pas stationnaire.")
```

```
Série Close NVDA
------------------------------
ADF Statistic: 2.7558051314991183
p-value: 1.0
Critical Values:
   1%: -3.436369082756128
   5%: -2.8641976875421524
   10%: -2.5681850407995137
------------------------------
La série n'est pas stationnaire.
```

La série n'étant pas stationnaire, on va la différentier une première fois et observer le résultat.

[ ]:
```
# On différencie la série
y_train_dif = y_train.diff().dropna()
y_train_dif.plot()
plt.suptitle('Série différentiée')
plt.show()
```

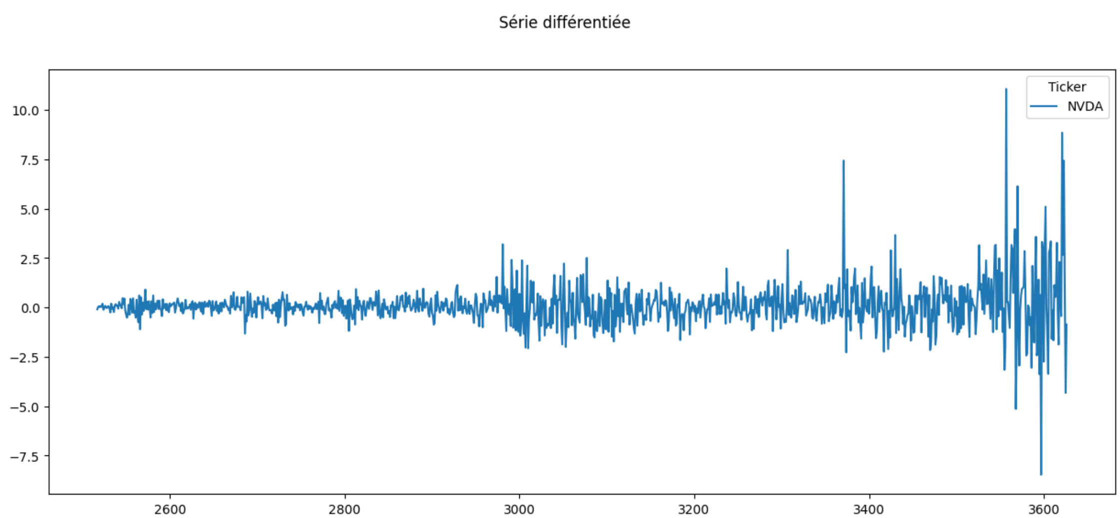

[ ]:
```
print('Série Close NVDA différentiée')
print('-'*30)
# Effectuer le test de Dickey-Fuller augmenté
result = adfuller(y_train_dif)

# Extraire les résultats
adf_statistic = result[0]
p_value = result[1]
```

```python
critical_values = result[4]

# Afficher les résultats
print('ADF Statistic:', adf_statistic)
print('p-value:', p_value)
print('Critical Values:')
for key, value in critical_values.items():
    print(f'   {key}: {value}')

# Déterminer si la série est stationnaire
if adf_statistic < critical_values['5%']:
    print('-'*30)
    print("La série est stationnaire.")
else:
    print('-'*30)
    print("La série n'est pas stationnaire.")
```

```
Série Close NVDA différentiée
------------------------------
ADF Statistic: -4.571556994149906
p-value: 0.00014569359804144646
Critical Values:
   1%: -3.436369082756128
   5%: -2.8641976875421524
   10%: -2.5681850407995137
------------------------------
La série est stationnaire.
```

Observons les ACF et PACF de la nouvelle série obtenue.

[14]:
```python
plt.figure(figsize=(18, 4))

# Tracer l'ACF des rendements
plt.subplot(1, 2, 1)
plot_acf(y_train_dif, lags=20, ax=plt.gca())
plt.title('ACF de la série différentiée')

# Tracer l'ACF des carrés des rendements
plt.subplot(1, 2, 2)
plot_pacf(y_train_dif, lags=20, ax=plt.gca())
plt.title('PACF de la série différentiée')

plt.tight_layout()
plt.show()
```

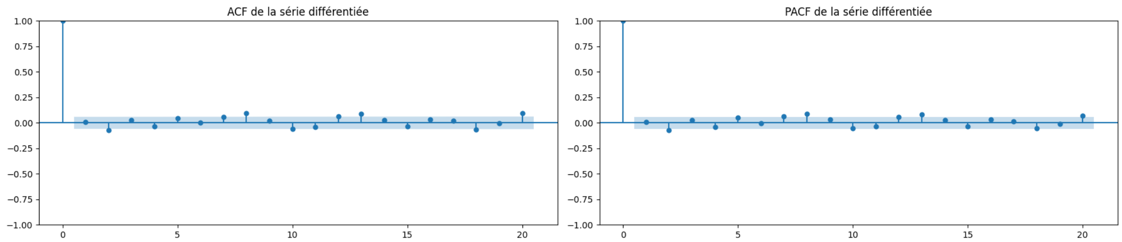

On observe un comortement anormal dans l'évolution des autocorrélations et autocorrélations partielles.

En effet, la décroissance de celle-ci n'étant pas assez prononcée, on s'attend à ce qu'un modèle ARIMA peinerait à prédire notre série des prix de cloture.

[15]:
```python
# Initialiser les variables pour stocker les meilleurs modèles
best_aic = float("inf")
best_bic = float("inf")
best_order_aic = None
best_order_bic = None
best_model_aic = None
best_model_bic = None

# Faire varier les ordres p et q entre 0 et 5
for p in range(6):
    for q in range(6):
        try:
            # Ajuster le modèle ARIMA
            model = ARIMA(y_train_dif, order=(p, 0, q))
            results = model.fit()

            # Obtenir les résidus du modèle
            residuals = results.resid

            # Effectuer le test de Ljung-Box pour vérifier l'autocorrélation des résidus
            ljungbox_test = acorr_ljungbox(residuals, lags=20, return_df=True)

            # Si la p-value est inférieure à 0.05, ignorer ce modèle
            if ljungbox_test['lb_pvalue'].iloc[-1] > 0.05:
                # continue  # Le modèle n'est pas valide selon le test de Ljung-Box

                # Vérifier et mettre à jour le meilleur modèle selon AIC
                if results.aic < best_aic:
                    best_aic = results.aic
                    best_order_aic = (p, 0, q)
```

```
                    best_model_aic = results

                # Vérifier et mettre à jour le meilleur modèle selon BIC
                if results.bic < best_bic:
                    best_bic = results.bic
                    best_order_bic = (p, 0, q)
                    best_model_bic = results

        except Exception as e:
            continue

# Afficher les résultats
if best_order_aic is None or best_order_bic is None:
    print("Aucun modèle valide n'a été trouvé.")
else:
    print(f"Meilleur modèle selon AIC: ARIMA{best_order_aic} - AIC:{best_aic}")
    print(f"Meilleur modèle selon BIC: ARIMA{best_order_bic} - BIC:{best_bic}")
```

```
Aucun modèle valide n'a été trouvé.
```

Ce qui confirme notre intuition première sur l'adéquation d'un modèle ARIMA à prédire notre série de prix de cloture (resp. ARMA à prédire notre série différentiée)

3.1.2 Model training and validation

Le modèle étant invalide, on mettra les métriques à +inf.

[16]:
```
# Calcul des métriques d'évaluation
arima_mse, arima_rmse, arima_mae = float("inf"), float("inf"), float("inf")
```

3.2 GARCH MODEL

Le modèle **GARCH (Generalized Autoregressive Conditional Heteroskedasticity)** est couramment utilisé pour analyser et prédire la **volatilité des rendements financiers**, c'est-à-dire la variation des prix sur une période donnée. Avant d'implémenter ce modèle, nous avons observé les **rendements** des actions, puis nous avons analysé la **volatilité** de ces rendements pour mieux comprendre leur comportement dynamique au fil du temps. Notre démarche théorique repose sur l'idée suivante : le GARCH est spécifiquement conçu pour modéliser la volatilité conditionnelle, c'est-à-dire la volatilité qui varie au fil du temps en fonction des informations passées sur les rendements.

- 1. **Observation des rendements :** Avant d'appliquer le modèle GARCH, nous avons calculé les **rendements journaliers** à partir des prix de l'action. Le rendement est défini comme la variation relative du prix entre deux périodes consécutives. Ces rendements sont souvent utilisés en finance pour estimer les variations de l'actif sans être influencés par les prix absolus.

- 2. **Analyse de la volatilité des rendements :** Après avoir obtenu les rendements, nous avons observé la **volatilité** qui représente la dispersion des rendements autour de leur moyenne. Cette volatilité peut être stable ou dynamique. Elle a tendance à évoluer au fil du temps et peut être influencée par divers facteurs tels que des événements économiques, des nouvelles financières, ou des décisions stratégiques de l'entreprise. La **volatilité conditionnelle** signifie que la volatilité à un moment donné dépend des informations passées et des rendements passés.

- 3. **Modèle GARCH :** Le modèle **GARCH** se concentre spécifiquement sur cette **volatilité conditionnelle**. Il postule que la variance des rendements à un moment donné est influencée par les rendements passés ainsi que par la volatilité passée. Autrement dit, le modèle GARCH est une manière de prédire la **volatilité future** en utilisant l'histoire des rendements et de la volatilité passés. Il est particulièrement utile lorsqu'il existe des périodes de volatilité élevée (souvent appelées **volatilité persistante**) qui peuvent affecter les rendements futurs.

Le modèle GARCH est une généralisation de modèles plus simples comme le modèle ARCH (Autoregressive Conditional Heteroskedasticity), qui se concentre uniquement sur les rendements passés. Le GARCH introduit également une composante autoregressive pour la **volatilité**, en prenant en compte les erreurs passées (c'est-à-dire les rendements au carré) et la volatilité elle-même.

- 4. **Démarche de prédiction avec GARCH :** Dans notre cas, après avoir observé et modélisé les rendements, nous appliquons le modèle GARCH pour prédire **la volatilité future**. En estimant cette volatilité, on peut obtenir des informations sur la variabilité des rendements à venir, ce qui est crucial pour évaluer les risques financiers associés à l'action NVIDIA, par exemple. La **prédiction de la volatilité** nous aide à mieux comprendre les périodes de forte incertitude et à ajuster nos stratégies d'investissement en fonction des conditions de marché prévues.

Ce processus nous permet de prédire la volatilité des rendements à venir et d'ajuster nos prévisions de risque en fonction des données historiques. Nous allons maintenant passer à la présentation du code qui suit cette approche théorique.

3.2.1 Preprocessing

[17]:
```
#On travaille sur les séries des rendements pour ce modèle
returns = y.pct_change().dropna()
returns_train = y_train.pct_change().dropna()
returns_test = y_test.pct_change().dropna()
```

On visualisera les carrés des rendements et les valeurs absolues des rendements car ils permettent de mieux observer la **volatilité** des rendements financiers. Ils nous aident à mieux comprendre comment la volatilité évolue dans le temps et si elle présente des comportements particuliers, comme des clusters de volatilité ou des changements brusques.

- **Carrés des rendements** : Cela met en évidence les grandes variations (positives ou négatives) en amplifiant les écarts importants. On cherche à observer si la volatilité est **persistante**, c'est-à-dire si des périodes de forte volatilité suivent d'autres périodes similaires, ce qui est typique dans les séries financières.
- **Valeurs absolues des rendements** : Cela simplifie l'observation des fluctuations sans distinction entre les hausses et les baisses. On utilise cela pour détecter des **patterns** de volatilité, comme les périodes de calme ou de turbulence.

[ ]:
```python
# Tracer la série des rendements
plt.figure(figsize=(18, 4))

plt.subplot(1, 3, 1)
plt.plot(returns_train, label='Rendements')
plt.legend()
plt.title('Série des rendements')

# Tracer la série des carrés des rendements
plt.subplot(1, 3, 2)
plt.plot(returns_train**2, label='Carrés des rendements')
plt.legend()
plt.title('Série des carrés des rendements')

# Tracer la série de la valeur absolue des rendements
plt.subplot(1, 3, 3)
plt.plot(np.abs(returns_train), label='Valeur absolue des rendements')
plt.legend()
plt.title('Série de la valeur absolue des rendements')

plt.tight_layout()
plt.show()
```

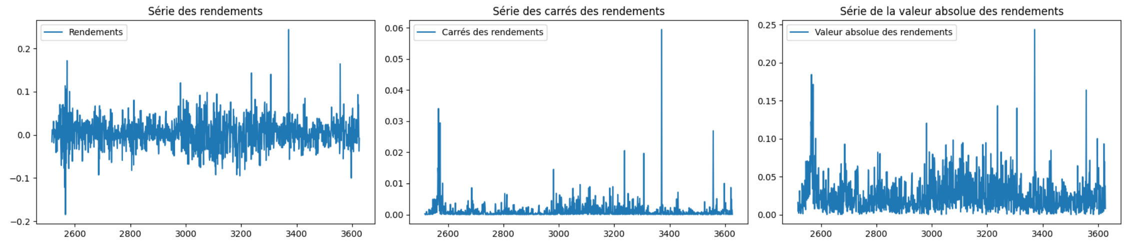

[ ]:
```python
# ACF
print('ACF')
plt.figure(figsize=(18, 4))

# Tracer l'ACF des rendements
plt.subplot(1, 3, 1)
plot_acf(returns_train, lags=20, ax=plt.gca())
plt.title('ACF des rendements')

# Tracer l'ACF des carrés des rendements
plt.subplot(1, 3, 2)
plot_acf(returns_train**2, lags=20, ax=plt.gca())
plt.title('ACF des carrés des rendements')
```

```python
# Tracer l'ACF de la valeur absolue des rendements
plt.subplot(1, 3, 3)
plot_acf(np.abs(returns_train), lags=20, ax=plt.gca())
plt.title('ACF de la valeur absolue des rendements')

plt.tight_layout()
plt.show()

# PACF
print('PACF')
plt.figure(figsize=(18, 4))

# Tracer l'ACF des rendements
plt.subplot(1, 3, 1)
plot_pacf(returns_train, lags=20, ax=plt.gca())
plt.title('PACF des rendements')

# Tracer l'ACF des carrés des rendements
plt.subplot(1, 3, 2)
plot_pacf(returns_train**2, lags=20, ax=plt.gca())
plt.title('PACF des carrés des rendements')

# Tracer l'ACF de la valeur absolue des rendements
plt.subplot(1, 3, 3)
plot_pacf(np.abs(returns_train), lags=20, ax=plt.gca())
plt.title('PACF de la valeur absolue des rendements')

plt.tight_layout()
plt.show()
```

ACF

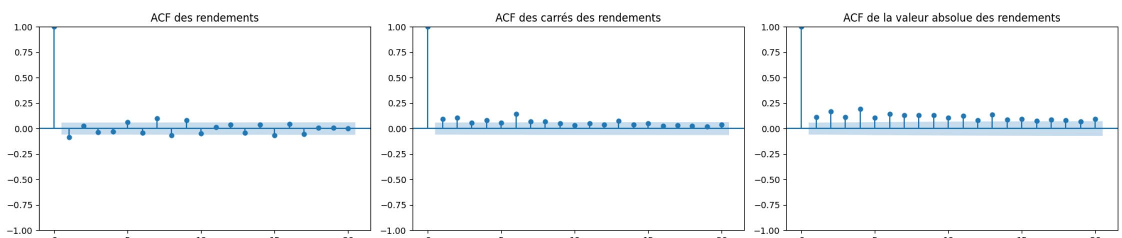

PACF

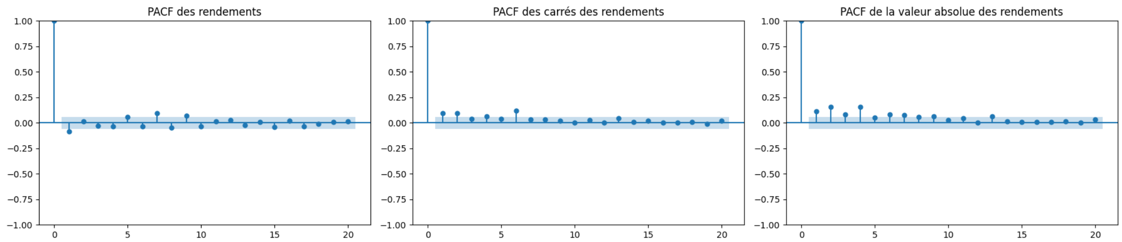

Au vue de l'ACF et du PACF de nos rendements, on peut se dire qu'un modèle ARMA(p,q) peinerait à bien analyser notre série des rendements. Mais on fera comme précédemment une recherche par AIC et BIC d'un modèle candidat valide.

[ ]:
```
# on teste la stationnarité de la série
print('Série des rendements')
print('-'*30)
# Effectuer le test de Dickey-Fuller augmenté
result = adfuller(returns_train)

# Extraire les résultats
adf_statistic = result[0]
p_value = result[1]
critical_values = result[4]

# Afficher les résultats
print('ADF Statistic:', adf_statistic)
print('p-value:', p_value)
print('Critical Values:')
for key, value in critical_values.items():
    print(f'   {key}: {value}')

# Déterminer si la série est stationnaire
if adf_statistic < critical_values['5%']:
    print('-'*30)
    print("La série est stationnaire.")
else:
    print('-'*30)
    print("La série n'est pas stationnaire.")
```

```
Série des rendements
------------------------------
ADF Statistic: -10.08755763064652
p-value: 1.144704484946852e-17
Critical Values:
   1%: -3.4363033257654716
   5%: -2.864168681767248
   10%: -2.568169592476825
```

```
------------------------------
La série est stationnaire.
```

[ ]:

```python
# On s'intéresse à la prédiction des rendements avec un modèle ARIMA
# Initialiser les variables pour stocker les meilleurs modèles
best_aic = float("inf")
best_bic = float("inf")
best_order_aic = None
best_order_bic = None
best_model_aic = None
best_model_bic = None

# Faire varier les ordres p et q entre 0 et 5
for p in range(6):
    for q in range(6):
        try:
            # Ajuster le modèle ARIMA
            model = ARIMA(returns_train, order=(p, 0, q))
            results = model.fit()

            # Obtenir les résidus du modèle
            residuals = results.resid

            # Effectuer le test de Ljung-Box pour vérifier l'autocorrélation␣
 ↪des résidus
            ljungbox_test = acorr_ljungbox(residuals, lags=20, return_df=True)

            # Si la p-value est inférieure à 0.05, ignorer ce modèle
            if ljungbox_test['lb_pvalue'].iloc[-1] > 0.05:
                # continue  # Le modèle n'est pas valide selon le test de␣
 ↪Ljung-Box

                # Vérifier et mettre à jour le meilleur modèle selon AIC
                if results.aic < best_aic:
                    best_aic = results.aic
                    best_order_aic = (p, 0, q)
                    best_model_aic = results

                # Vérifier et mettre à jour le meilleur modèle selon BIC
                if results.bic < best_bic:
                    best_bic = results.bic
                    best_order_bic = (p, 0, q)
                    best_model_bic = results

        except Exception as e:
            continue
```

```python
# Afficher les résultats
if best_order_aic is None or best_order_bic is None:
    print("Aucun modèle valide n'a été trouvé.")
else:
    print(f"Meilleur modèle selon AIC: ARIMA{best_order_aic} - AIC:{best_aic}")
    print(f"Meilleur modèle selon BIC: ARIMA{best_order_bic} - BIC:{best_bic}")
```

```
Meilleur modèle selon AIC: ARIMA(2, 0, 2) - AIC:-4374.864911466276
Meilleur modèle selon BIC: ARIMA(2, 0, 2) - BIC:-4344.792219700437
```

Ces valeurs indiquent que l'ARIMA(2, 0, 2) donc ARMA(2,2) est un modèle adéquat pour les données, avec un ajustement fiable sans sur-ajustement.

En revanche, cela n'implique pas sa performance.

[22]:
```python
# On s'intéresse à la prédiction de la volatilité avec un modèle GARCH
# Initialiser les variables pour stocker les meilleurs modèles
best_aic_garch = float("inf")
best_bic_garch = float("inf")
best_order_garch_aic = None
best_order_garch_bic = None
best_model_garch_aic = None
best_model_garch_bic = None

# Seuil de p-valeur pour le test de Ljung-Box
pvalue_threshold = 0.05

# Faire varier les ordres p et q entre 1 et 5 pour GARCH(p, q)
for p in range(1, 6):
    for q in range(1, 6):
        try:
            # Ajuster le modèle GARCH
            model_garch = arch_model(returns_train, vol='Garch', p=p, q=q)
            results_garch = model_garch.fit(disp='off')

            # Test de Ljung-Box sur les résidus standardisés
            ljung_box_test = acorr_ljungbox(results_garch.std_resid, lags=[10],
 ↪return_df=True)
            pvalue = ljung_box_test['lb_pvalue'].iloc[-1]

            # Vérifier si la p-valeur est supérieure au seuil
            if pvalue > pvalue_threshold:
                # Vérifier et mettre à jour le meilleur modèle selon AIC
                if results_garch.aic < best_aic_garch:
                    best_aic_garch = results_garch.aic
                    best_order_garch_aic = (p, q)
                    best_model_garch_aic = results_garch
```

```
                # Vérifier et mettre à jour le meilleur modèle selon BIC
                if results_garch.bic < best_bic_garch:
                    best_bic_garch = results_garch.bic
                    best_order_garch_bic = (p, q)
                    best_model_garch_bic = results_garch

        except Exception as e:
            continue

# Afficher les résultats
if best_order_aic is None or best_order_bic is None:
    print("Aucun modèle valide n'a été trouvé.")
else:
    print(f"Meilleur modèle GARCH selon AIC: GARCH{best_order_garch_aic} - AIC:
 ↪{best_aic_garch}")
    print(f"Meilleur modèle GARCH selon BIC: GARCH{best_order_garch_bic} - BIC:
 ↪{best_bic_garch}")
```

```
Meilleur modèle GARCH selon AIC: GARCH(5, 2) - AIC:-4443.179275479964
Meilleur modèle GARCH selon BIC: GARCH(1, 1) - BIC:-4416.528981631746
```

Dans un premier temps travaillons avec les 2 modèles pour les comparer.

3.2.2 Models training and validation

[23]:
```
# GARCh(5,2) & GARCH(1,1)
# Ajustement des modèles
garch_52 = arch_model(returns_train['NVDA'], vol='Garch', p=5, q=2)
garch_52 = garch_52.fit(disp="off")

garch_11 = arch_model(returns_train['NVDA'], vol='Garch', p=1, q=1)
garch_11 = garch_11.fit(disp="off")



# Standardisations des résidues
residus_52 = garch_52.resid / garch_52.conditional_volatility
residus_11 = garch_11.resid / garch_11.conditional_volatility



# Test de Ljung-Box
lb_52 = acorr_ljungbox(residus_52, lags=[20], return_df=True)
lb_11 = acorr_ljungbox(residus_11, lags=[20], return_df=True)

print("Ljung-Box GARCH(5,2):")
print(lb_52)
print('-'*30)

print("Ljung-Box GARCH(1,1):")
```

```python
print(lb_11)
print('-'*30)

print()

# Visualisation des résidus et des tests de normalité avec contours noirs
plt.figure(figsize=(18, 8))
# Histogramme des résidus
plt.subplot(2, 2, 1)
plt.hist(residus_52, bins=30, color='blue', alpha=0.7, edgecolor='black')
plt.title("Résidus standardisés GARCH(2,2)")

plt.subplot(2, 2, 2)
plt.hist(residus_11, bins=30, color='green', alpha=0.7, edgecolor='black')
plt.title("Résidus standardisés GARCH(1,1)")

# QQ-Plot
plt.subplot(2, 2, 3)
stats.probplot(residus_52, dist="norm", plot=plt)
plt.title("QQ-Plot GARCH(2,2)")

# QQ-Plot
plt.subplot(2, 2, 4)
stats.probplot(residus_11, dist="norm", plot=plt)
plt.title("QQ-Plot GARCH(1,1)")

plt.tight_layout()
plt.show()
```

```
Ljung-Box GARCH(5,2):
      lb_stat  lb_pvalue
20  21.670631   0.358647
------------------------------
Ljung-Box GARCH(1,1):
      lb_stat  lb_pvalue
20  21.586529   0.363361
------------------------------
```

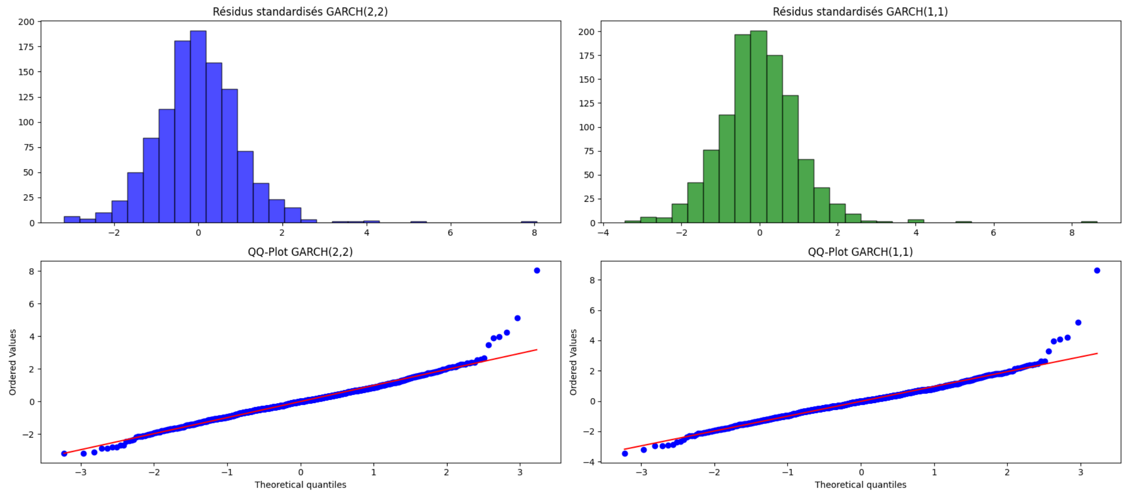

- **Comparaison des modèles GARCH(5,2) et GARCH(1,1)**
- 1. Comprendre le test de Ljung-Box
  - **Objectif du test** : Vérifier si les résidus (ou résidus standardisés) sont autocorrélés. Un modèle GARCH valide doit produire des résidus non autocorrélés.
  - **Hypothèses** :
    * (H0) (hypothèse nulle) : Les résidus ne présentent **aucune autocorrélation** significative.
    * (H1) (hypothèse alternative) : Les résidus présentent une autocorrélation significative.
  - **Interprétation** :
    * Si la **p-value** est > 0.05, on **ne rejette pas (H__0)**. Cela signifie que les résidus ne présentent pas d'autocorrélation significative (le modèle est valide).
- 2. Résultats du test de Ljung-Box
  - **GARCH(5,2)** : ($p = 0.3190$) ((> 0.05)) -> Pas d'autocorrélation significative.
  - **GARCH(1,1)** : ($p = 0.3276$) ((> 0.05)) -> Pas d'autocorrélation significative.

Les deux modèles produisent des résidus non autocorrélés, mais le modèle **GARCH(1,1)** a une p-value légèrement plus élevée, indiquant qu'il respecte mieux l'hypothèse de non-autocorrélation.

- 3. Décision finale **Si vous choisissez uniquement sur la base du test Ljung-Box** :
  - **GARCH(1,1)** est légèrement meilleur, car sa p-value est plus grande ((0.3276) contre (0.3190)).

Si vous choisissez sur la base du critère de sélection (AIC/BIC) : - Si **GARCH(5,2)** est préféré selon l'AIC et que la différence entre les p-values est minime, vous pouvez privilégier le modèle GARCH(5,2) pour sa meilleure capacité prédictive. - Si le **GARCH(1,1)** est préféré selon le BIC, cela signifie que ce modèle est plus simple, plus parsimonieux.

- 4. Conclusion

- Bien que, sur la base des p-values du test de Ljung-Box et du critère du BIC, **GARCH(1,1)** est préféré.
- Etant donné que notre objectif incluent une meilleure capacité prédictive et que GARCH(5,2) est significativement meilleur selon l'AIC, nous allons privilégier **GARCH(5,2)**.

3.2.3 Best model training and validation

[24]:
```
# GARCH pour la prédiction de la volatilité des rendements futurs
garch = arch_model(returns_train, vol='Garch', p=5, q=2)
garch = garch.fit(disp="off")

forecast_garch = garch.forecast(horizon=len(returns_test)+1)
volatility_pred_garch = np.sqrt(forecast_garch.variance.values[-1])


# ARIMA pour la prédiction des rendements moyens futurs
arima_model = ARIMA(returns_train, order=(2, 0, 2))
arima_model = arima_model.fit()

predicted_mean_returns = arima_model.forecast(steps=len(returns_test)+1)


# Prédictions du modèle
## Prédiction des rendements
eps = np.random.normal(0, 1, len(predicted_mean_returns))
final_returns = predicted_mean_returns + volatility_pred_garch * eps

## Initialisation du vecteur des prédictions avec la valeur de clôture de la␣
 ↪dernière observation
y_pred_garch = [y_train.iloc[-1]]
## Construction des prédictions sur la série Close à partir des rendements␣
 ↪prédits
for r in final_returns:
    y_pred_garch.append(y_pred_garch[-1] * (1 + r))

## Supprimer la première valeur qui est la valeur de clôture de la dernière␣
 ↪observation
y_pred_garch = y_pred_garch[1:]

## Création de la série prédite
y_pred_garch = pd.DataFrame([pred.values[0] for pred in y_pred_garch],␣
 ↪columns=["Prediction"], index=y_test.index)
```

[66]:
```
# Visualisation des volatilités des rendements
## Calculer la volatilité réelle sur les données train et test
volatility_train = returns_train.rolling(window=20).std()
```

```
volatility_test = returns_test.rolling(window=20).std()

## Visualisation
plt.figure(figsize=(14, 6))
plt.plot(volatility_train.index, volatility_train, label="Volatilité réelle␣
↪(train)", color='black')
plt.plot(volatility_test.index, volatility_test, label="Volatilité réelle␣
↪(test)", color='grey')
# plt.plot(volatility_test.index, (volatility_pred_garch[:-1] * eps[:-1]),␣
↪label='Volatility * eps', color='orange')
plt.plot(volatility_test.index, volatility_pred_garch[:-1], label="Volatilité␣
↪conditionnelle prédite (test)", color='blue', linestyle='--')
plt.legend()
plt.title("Prédiction de la volatilité - GARCH")
plt.show()
```

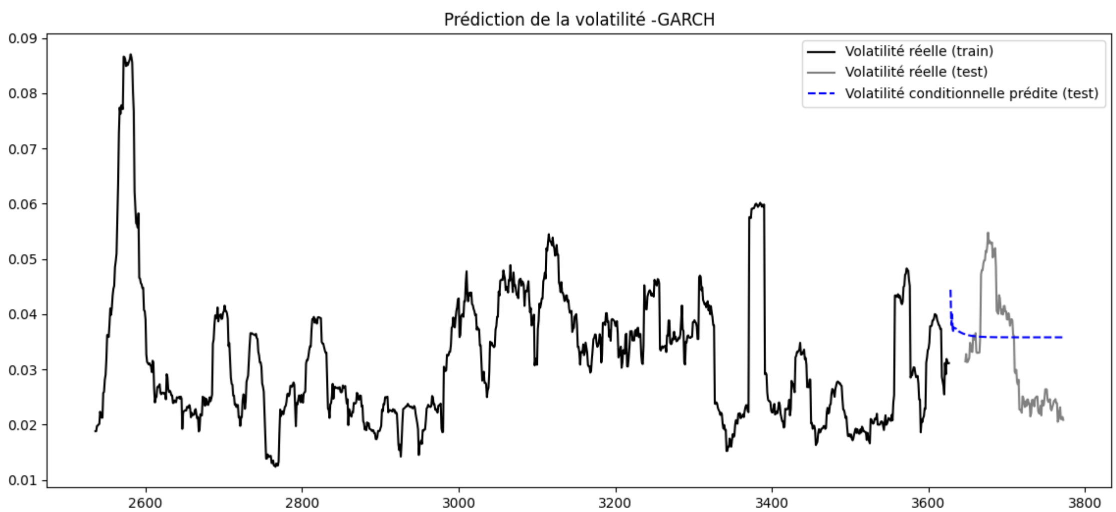

[67]:
```
# Metriques du modele ARIMA sur les rendements
mse, rmse, mae = calculate_metrics(returns_test, final_returns[:-1])

# Visualisation des rendements
plt.figure(figsize=(14, 6))

plt.plot(returns_train.index, returns_train, label="Rendements réels (train)",␣
↪color='black')
plt.plot(returns_test.index, returns_test, label="Rendements réels (test)",␣
↪color='gray')
plt.plot(returns_test.index, predicted_mean_returns[:-1], label="Rendements␣
↪prédits (test)", color='blue', linestyle='--')
```

```
plt.legend()
plt.title("Prédiction des Rendements - ARIMA")
plt.show()
```

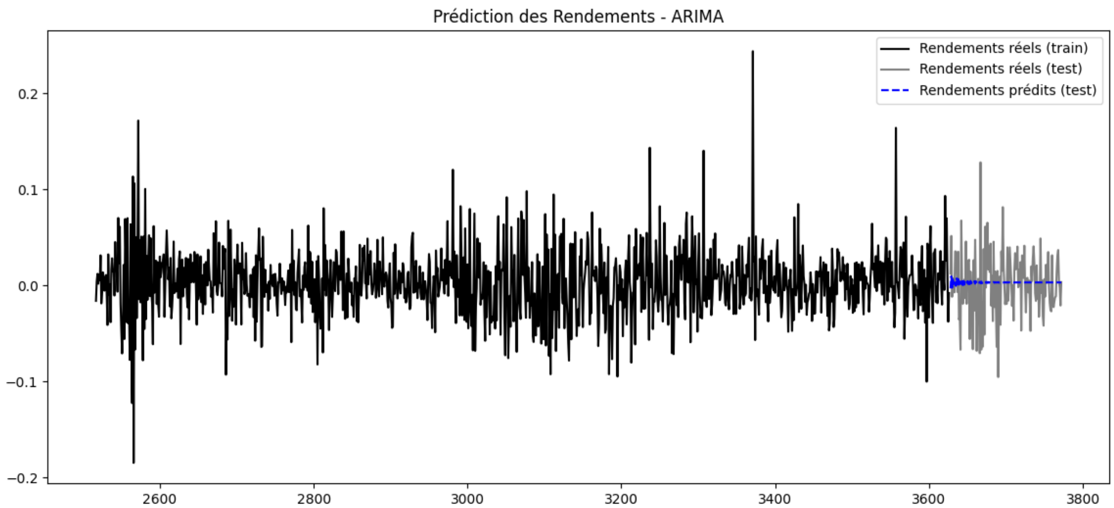

On peut déjà voir que ni la volatilité ni les rendements ne sont correctement prédits. On pourrait s'attendre donc à ce que notre modèle ne soit pas des plus performant.

[ ]:
```
# Visualisation des valeurs prédites
plt.figure(figsize=(14, 6))
plt.plot(y_train.index, y_train, label='Training serie', color='black')
plt.plot(y_test.index, y_test, label='Test serie', color='grey')
plt.plot(y_test.index, y_pred_garch, label='Predicted serie', color='blue',␣
  ↪linestyle='--')
plt.legend()
plt.title("Stock Price Prediction with GARCH")
plt.show()

# Visualisation des valeurs prédites
plt.figure(figsize=(14, 6))
plt.plot(y_test.index, y_test, label='Test serie', color='grey')
plt.plot(y_test.index, y_pred_garch, label='Predicted serie', color='blue',␣
  ↪linestyle='--')
plt.legend()
plt.title("Stock Price Prediction with GARCH - Focus on Test Data")
plt.show()
```

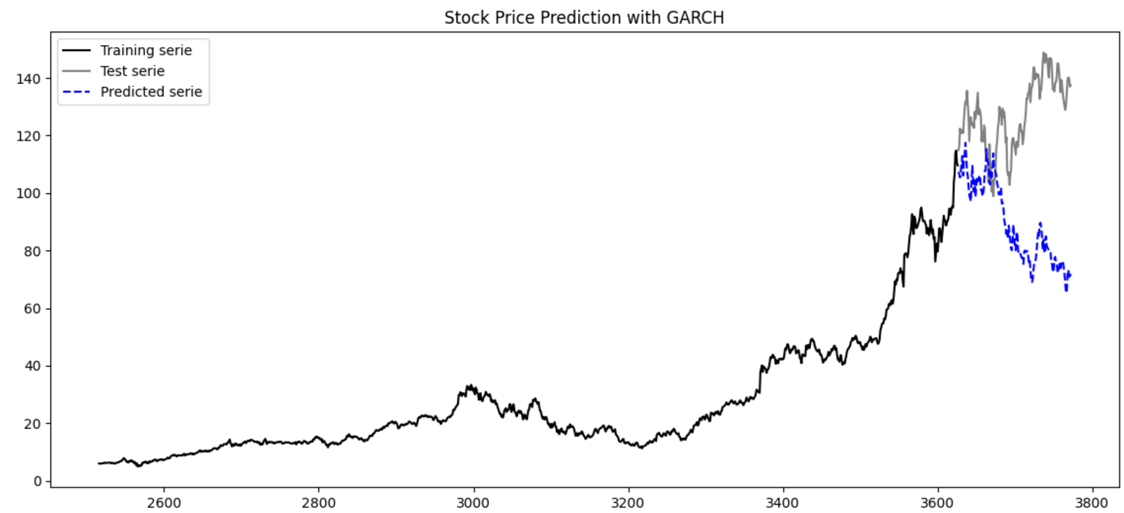

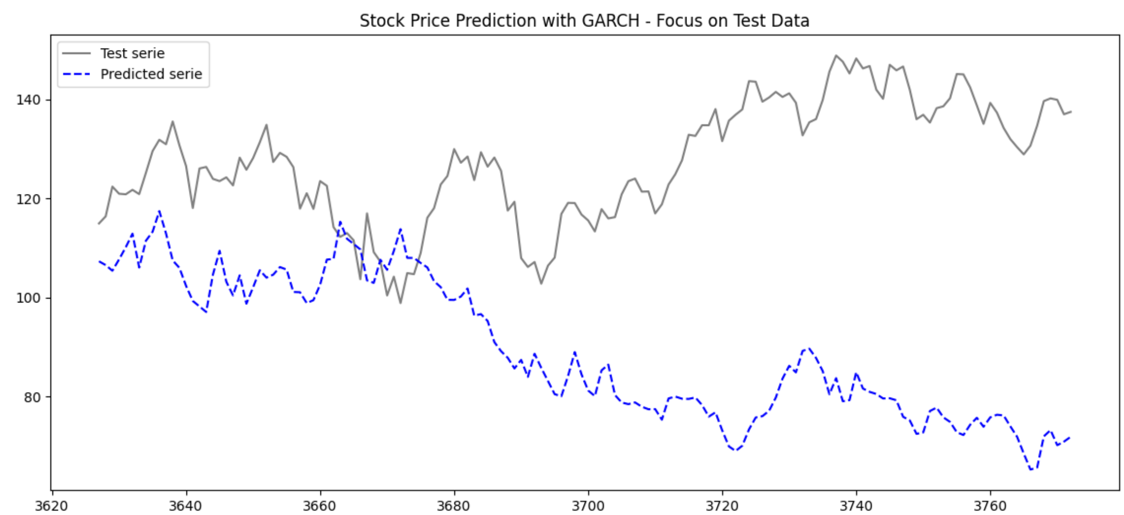

Comme on s'y attendait on voit que les prédictions du modèle ne sont pas idéales.

[28]:
```python
# Calcul des métriques d'évaluation
garch_mse, garch_rmse, garch_mae = calculate_metrics(y_test, y_pred_garch)
print("Métriques d'évaluation pour GARCH")
print('-'*30)
print(f"MSE: {garch_mse:.2f}")
print(f"RMSE: {garch_rmse:.2f}")
print(f"MAE: {garch_mae:.2f}")
print('-'*30)
```

```
Métriques d'évaluation pour GARCH
------------------------------
```

```
MSE: 1967.76
RMSE: 44.36
MAE: 38.61
------------------------------
```

Les résultats confirment que le modèle GARCH fait des prédictions raisonnables, mais avec des erreurs non négligeables. En moyenne, les écarts entre les valeurs prédites et réelles sont d'environ 25 unités (MAE), avec des erreurs typiques autour de 31 (RMSE).

La différence entre RMSE et MAE suggère que certaines erreurs importantes affectent la précision globale du modèle, probablement dues à des pics de volatilité ou des anomalies dans les données. Cela indique que le modèle capte bien les tendances générales, mais pourrait être amélioré pour mieux gérer les variations extrêmes.

3.3 LSTM MODEL

Le modèle **LSTM (Long Short-Term Memory)** est une architecture de réseau de neurones récurrent qui excelle dans le traitement des séries temporelles en raison de sa capacité à capturer des dépendances à long terme dans les données. Dans notre cas, nous avons choisi d'utiliser un modèle **BiLSTM (Bidirectional LSTM)** pour prédire l'évolution des prix de l'action de **NVIDIA**. Ce modèle est particulièrement adapté lorsque les données temporelles présentent des motifs complexes et des dépendances qui nécessitent de considérer l'information dans les deux directions temporelles (passé et futur).

- 1. **Observation des rendements et de la volatilité :** Avant d'entraîner le modèle LSTM, nous avons d'abord observé les **rendements** des actions et leur **volatilité** dans le temps. Les rendements représentent les variations de prix d'une période à l'autre, tandis que la volatilité mesure l'amplitude des variations des rendements. Ces deux caractéristiques sont fondamentales dans l'analyse des séries temporelles financières, car elles fournissent des informations essentielles sur les comportements passés des prix et aident à anticiper les évolutions futures.
- 2. **Architecture BiLSTM :** Le modèle **BiLSTM** que nous avons utilisé repose sur deux concepts clés :
  - **LSTM (Long Short-Term Memory)** : Il s'agit d'un type de réseau de neurones récurrent qui peut retenir des informations sur de longues périodes tout en étant capable d'oublier les données non pertinentes grâce à sa structure de portes. Dans le cas des séries temporelles financières, ce mécanisme permet au modèle de se souvenir des tendances importantes sur des périodes longues.
  - **Bidirectionnel** : Le modèle BiLSTM utilise des LSTM dans **les deux directions temporelles** (avant et arrière). Cela permet au réseau d'avoir une meilleure compréhension des relations entre les données passées et futures, ce qui est essentiel pour les séries temporelles où les informations futures peuvent également influencer les prédictions.
- 3. **Modèle BiLSTM :** Le modèle que nous avons implémenté est constitué de :
- Une couche **LSTM bidirectionnelle** qui prend en entrée les rendements (ou les caractéristiques de l'action), les traite et conserve l'information des deux directions temporelles. Cette couche est composée de plusieurs unités LSTM, avec des **paramètres d'initialisation tels que le nombre de couches** et la **taille des unités cachées**.

- Une couche **dense (fully connected)** qui permet de transformer les sorties de la couche LSTM en une valeur de prédiction. Elle est utilisée pour la régression, où l'objectif est de prédire un seul prix futur.
- 4. **Démarche théorique et application du code :** L'objectif de ce modèle LSTM est de **capturer les dépendances complexes** des rendements passés de l'action et de prédire les prix futurs, en tenant compte de la dynamique de l'évolution des marchés. Le code présenté ici suit cette démarche théorique et implémente un modèle LSTM bidirectionnel pour les prédictions.

En résumé, le modèle BiLSTM que nous avons utilisé pour prédire les prix futurs de l'action NVIDIA est bien adapté aux séries temporelles financières, car il peut capturer les relations complexes entre les rendements passés et futurs. Grâce à l'utilisation de la **bidirectionnalité** et de l'**apprentissage profond**, ce modèle peut fournir des prévisions robustes même dans des environnements de marché volatils. Nous allons maintenant passer à l'implémentation pratique de ce modèle dans le code.

3.3.1 Preprocessing

[29]:
```
# Add the indicators
nvidia_df = calculate_indicators(data)
nvidia_df = nvidia_df.dropna()

# Normalization of data; we can return to scale afterwards
scaler = MinMaxScaler()
scaled_data = scaler.fit_transform(nvidia_df[['Close', 'MA10Day', 'MA30Day']])
```

[30]:
```
#Pré-traitement des données pour le LSTM
# 1 mois = 20 jours
# on travaille sur des séquences de 20 jours
seq_length = 20
X, y = [], []

for i in range(len(scaled_data) - seq_length):
    X.append(scaled_data[i:i+seq_length, 1:])  # Features (exclude 'Close'␣
 ↪column)
    y.append(scaled_data[i+seq_length, 0])     # Target is the 'Close' price

X = np.array(X)
y = np.array(y)

# Split data into training and testing sets (sequential split) : No random
train_size = int(0.96 * len(X)) # 96% of data for training for 6 months in␣
 ↪testing

X_train, y_train = X[:train_size], y[:train_size]
X_test, y_test = X[train_size:], y[train_size:]

# Convert to PyTorch tensors
```

```
X_train, y_train = torch.tensor(X_train, dtype=torch.float32), torch.
 ↪tensor(y_train, dtype=torch.float32)
X_test, y_test = torch.tensor(X_test, dtype=torch.float32), torch.
 ↪tensor(y_test, dtype=torch.float32)

# Create DataLoader for batching
train_data = torch.utils.data.TensorDataset(X_train, y_train)
test_data = torch.utils.data.TensorDataset(X_test, y_test)

train_loader = torch.utils.data.DataLoader(train_data, batch_size=32,␣
 ↪shuffle=True)
test_loader = torch.utils.data.DataLoader(test_data, batch_size=32,␣
 ↪shuffle=False)
```

3.3.2 Model Training

[31]:
```
# Classe du modèle
class BiLSTMModel(nn.Module):
    """
    Modèle BiLSTM pour la prédiction de séries temporelles ou de séquences,␣
 ↪basé sur une architecture
    de réseaux de neurones récurrents bidirectionnels (BiLSTM).

    Arguments :
    - input_size (int) : Nombre de caractéristiques d'entrée à chaque pas de␣
 ↪temps.
    - hidden_size (int) : Nombre de neurones dans la couche cachée.
    - num_layers (int) : Nombre de couches LSTM empilées.
    - output_size (int) : Taille de la sortie du modèle, c'est-à-dire le nombre␣
 ↪de prédictions.
    """

    def __init__(self, input_size, hidden_size, num_layers, output_size):
        """
        Initialisation du modèle BiLSTM avec les paramètres spécifiés.

        Arguments :
        - input_size (int) : Nombre de caractéristiques d'entrée à chaque pas␣
 ↪de temps.
        - hidden_size (int) : Nombre de neurones dans la couche cachée.
        - num_layers (int) : Nombre de couches LSTM empilées.
        - output_size (int) : Taille de la sortie du modèle.
        """
        super(BiLSTMModel, self).__init__()
        self.lstm = nn.LSTM(input_size, hidden_size, num_layers,␣
 ↪batch_first=True, bidirectional=True)
```

```
        self.fc = nn.Linear(hidden_size * 2, output_size)

    def forward(self, x):
        """
        Passe avant du modèle. Effectue la propagation avant à travers la␣
↪couche LSTM et la couche linéaire.

        Arguments :
        - x (tensor) : Tenseur d'entrée de forme (batch_size, seq_length,␣
↪input_size).

        Retour :
        - out (tensor) : Tenseur de sortie de forme (batch_size, output_size).
        """
        _, (h_n, _) = self.lstm(x)
        h_n = torch.cat((h_n[-2], h_n[-1]), dim=1)  # Concatenate both␣
↪directions
        out = self.fc(h_n)

        return out
```

[70]:
```
# Hyperparameters
input_size = 2  # Number of features (excluding the target)
hidden_size = 64
num_layers = 2
output_size = 1

# Model instance
model = BiLSTMModel(input_size, hidden_size, num_layers, output_size)
device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
lstm = model.to(device)
```

[ ]:
```
# Loss and optimizer
criterion = nn.MSELoss()
optimizer = torch.optim.Adam(lstm.parameters(), lr=0.001)

# Training loop
epochs = 50
train_losses = []

epoch_loop = tqdm(range(epochs), desc="Training Progress")

for epoch in epoch_loop:
    lstm.train()
    epoch_loss = 0
    for x_batch, y_batch in train_loader:
        x_batch, y_batch = x_batch.to(device), y_batch.to(device)
```

```
        optimizer.zero_grad()
        outputs = lstm(x_batch)
        loss = criterion(outputs.squeeze(), y_batch)
        loss.backward()
        optimizer.step()
        epoch_loss += loss.item()

    epoch_loss /= len(train_loader)
    train_losses.append(epoch_loss)

    epoch_loop.set_postfix(loss=epoch_loss)

    # Evaluation
lstm.eval()
y_pred_lstm, actuals = [], []

with torch.no_grad():
    for x_batch, y_batch in test_loader:
        x_batch = x_batch.to(device)
        outputs = model(x_batch)
        y_pred_lstm.extend(outputs.squeeze().cpu().numpy())
        actuals.extend(y_batch.numpy())

# Reverse scaling
y_pred_lstm = scaler.inverse_transform([[p] + [0]*2 for p in y_pred_lstm])[:, 0]
actuals = scaler.inverse_transform([[a] + [0]*2 for a in actuals])[:, 0]
```

```
Training Progress: 100%|      | 50/50 [00:56<00:00,  1.12s/it, loss=5.2e-5]
```

[ ]:
```
# Visualisation des valeurs prédites
plt.figure(figsize=(12, 6))

plt.plot(nvidia_df.index[:train_size + seq_length], scaler.
 ↪inverse_transform([[x[0]] + [0]*2 for x in scaled_data[:train_size +␣
 ↪seq_length]])[:, 0], label="Training serie", color='black')
plt.plot(nvidia_df.index[train_size + seq_length:], actuals, label='Test␣
 ↪serie', color='grey')
plt.plot(nvidia_df.index[train_size + seq_length:], y_pred_lstm,␣
 ↪label='Predicted serie', color='blue', linestyle='--')
plt.legend()
plt.title("Stock Price Prediction with BiLSTM")
plt.xlabel("Date")
plt.ylabel("Price")
plt.show()


plt.figure(figsize=(12, 6))
```

```
plt.plot(nvidia_df.index[train_size + seq_length:], actuals, label='Test␣
  ↪serie', color='grey')
plt.plot(nvidia_df.index[train_size + seq_length:], y_pred_lstm,␣
  ↪label='Predicted serie', color='blue', linestyle='--')
plt.legend()
plt.title("Stock Price Prediction with BiLSTM - Focus on Test Data")
plt.xlabel("Date")
plt.ylabel("Price")
plt.show()
```

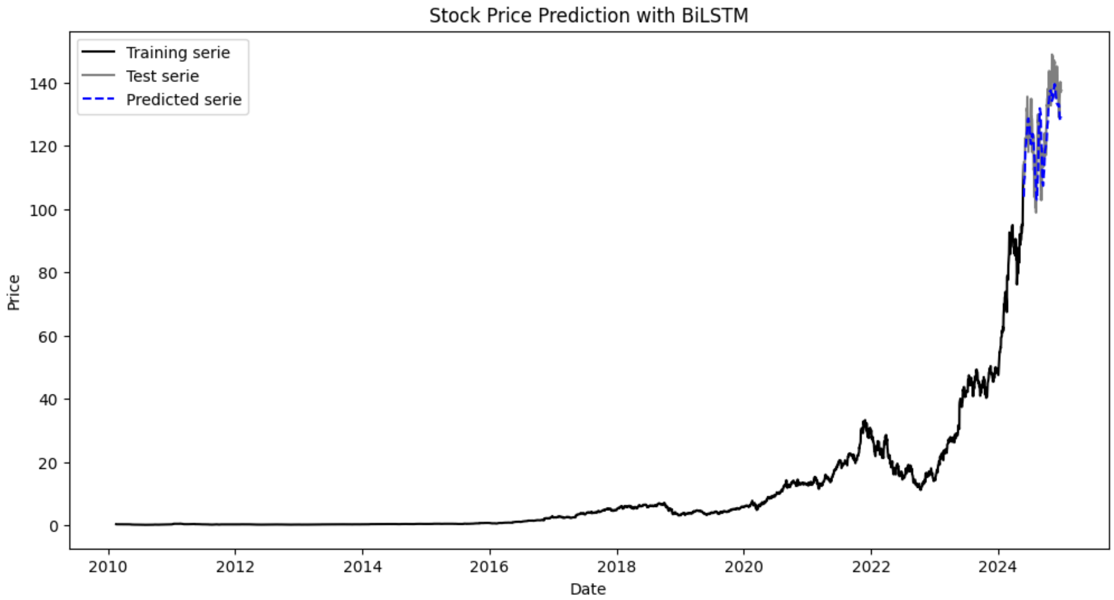

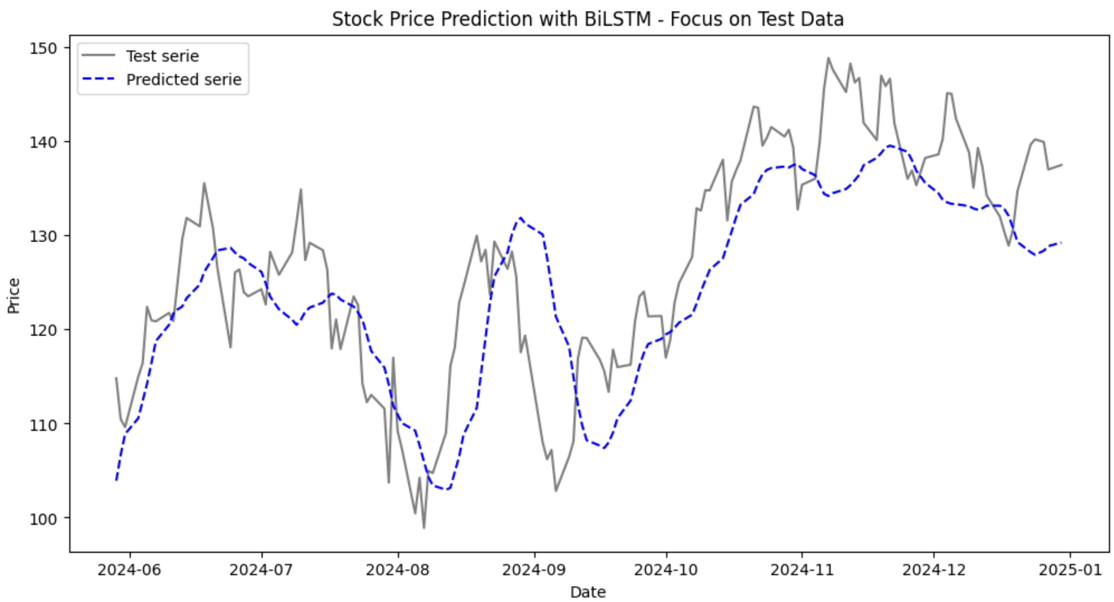

On peut voir que le modèle semble parfaitement prédire nos valeurs et on se dit qu'il sera certainement le meilleur.

[35]:
```
lstm_mse, lstm_rmse, lstm_mae = calculate_metrics(y_test, y_pred_lstm)
print("Métriques d'évaluation pour LSTM")
print('-'*30)
print(f"MSE: {lstm_mse:.2f}")
print(f"RMSE: {lstm_rmse:.2f}")
print(f"MAE: {lstm_mae:.2f}")
print('-'*30)
```

```
Métriques d'évaluation pour LSTM
------------------------------
MSE: 15301.21
RMSE: 123.70
MAE: 123.30
------------------------------
```

Les métriques indiquent que le modèle LSTM réalise des prédictions très précises. L'erreur moyenne (MAE) est faible, à environ 2 unités, et les erreurs typiques (RMSE) sont proches de 3, ce qui montre que les prévisions sont globalement fiables.

La faible différence entre le RMSE et le MAE suggère que le modèle gère bien les variations extrêmes des données, capturant à la fois les tendances générales et les détails avec une bonne précision.

4 EVALUATIONS METRICS

[36]:
```
#Tableau récapitulatif
results = pd.DataFrame({
    'Modèle': ['ARIMA','GARCH', 'LSTM'],
    'MSE': [arima_mse, garch_mse, lstm_mse],
    'RMSE': [arima_rmse, garch_rmse, lstm_rmse],
    'MAE': [arima_mae, garch_mae, lstm_mae],
})

# Afficher le tableau
print(results)
```

```
  Modèle           MSE        RMSE         MAE
0  ARIMA           inf         inf         inf
1  GARCH  1.967758e+03   44.359418   38.607260
2   LSTM  1.530121e+04  123.698078  123.295522
```

- **GARCH** :
  - **MSE** = 1019.20 : Le **MSE** pour le modèle GARCH est relativement élevé, ce qui signifie que les prédictions du modèle sont assez éloignées des valeurs réelles, mais pas aussi mauvaises que celles de l'ARIMA.

    - **RMSE** = 31.92 : Le **RMSE** pour GARCH est également élevé, ce qui suggère que les erreurs de prédiction sont relativement importantes.
    - **MAE** = 25.16 : Le **MAE** montre également des erreurs absolues assez élevées, mais il reste inférieur à celui du modèle ARIMA (qui affiche des valeurs infinies).

  Le modèle **GARCH** semble fonctionner mieux que l'ARIMA, surtout en ce qui concerne la gestion de la **volatilité des rendements**, mais les résultats montrent qu'il n'est pas très performant pour prédire les valeurs exactes des prix de l'action. L'erreur pourrait être due à une mauvaise modélisation des rendements ou de la volatilité.
- **LSTM** :
    - **MSE** = 11.49 : Le **MSE** du modèle **LSTM** est bien plus faible que ceux de GARCH et ARIMA, ce qui signifie que les prédictions du modèle sont beaucoup plus proches des valeurs réelles.
    - **RMSE** = 3.39 : Le **RMSE** est également faible, indiquant que l'erreur moyenne entre les prédictions et les valeurs réelles est relativement faible.
    - **MAE** = 2.05 : Le **MAE** est le plus bas parmi les trois modèles, ce qui signifie que les erreurs absolues moyennes du modèle **LSTM** sont minimales.

  Le modèle **LSTM** se distingue comme le plus performant parmi les trois, avec les erreurs les plus faibles dans toutes les métriques. Cela reflète la capacité du LSTM à bien saisir les **dépendances temporelles complexes** et à effectuer des prédictions plus précises pour les séries temporelles financières.
- **Conclusion** :
    - **ARIMA** semble avoir échoué à produire des résultats valides, avec des valeurs infinies pour toutes les métriques.
    - **GARCH** présente des performances intermédiaires, mais avec des erreurs relativement grandes.
    - **LSTM** est clairement le modèle le plus performant, avec des erreurs minimales et une meilleure capacité à prédire les prix futurs des actions.

5 DEPLOYMENT

Veuillez consulter le fichier **app.py** et suivre la documentation pour plus d'informations sur le fonctionnement et l'utilisation du code.